

# 画像処理を用いたマイクロバブル計測システムの開発

## Development of Microbubbles Measurement System Using Image Processing

複合工学専攻  
(Advanced Integrated Engineering Course)

石原理志  
(Satoshi ISHIHARA)

Microbubbles have the property of purifying water and have attracted much attention in the industry. However, the establishment of bubble measurement methods, which is a fundamental part of microbubble utilization, has been delayed. In this study, we investigate a method for extracting bubbles using deep learning YOLO. In order to use YOLO, it is necessary to perform annotation, which requires a lot of effort and time to create the training data. To address this issue, we propose a method to reduce the annotation effort for creating training data by combining image processing and manual annotation. Experiments were conducted on images that were not used for training. As a result, the proposed method reduces the annotation effort by about 40% while maintaining the extraction accuracy compared to the case where all annotations were done manually (F-measure is about 87%). In addition, if we can tolerate about 3% decrease in the extraction accuracy, we can reduce the annotation effort by about 70%. This suggests that system users can greatly reduce the effort of manual annotation and can easily realize bubble extraction using YOLO.

keyword: Image Processing, Deep Learning, Annotation, Microbubbles

## 1 諸言

マイクロバブルとは発生時の気泡直径が約 100 マイクロメートル以下の気泡ことで通常の気泡と比べると非常に小さなものである。この微細な気泡には様々なメリットがあることが分かっており、近年の産業界で期待が高まっている。その応用範囲は環境改善や農・水産業、医療などの広範な分野に及ぶ [1]。また、オゾンとの相性が良いことも大きな特徴であり、水処理や殺菌などの方面で実用的な取り組みがなされつつある。しかし、マイクロバブル活用での基盤的な部分であるバブルの評価方法や計測手法の確立が遅れている。そこで本稿では、画像処理と深層学習を用いてマイクロバブルの評価方法や計測手法の確立を目指す。

## 2 関連研究

気泡や粒子計測技術として、気泡や粒子を円や楕円と見なし検出する方法が提案されている。近年では深層学習を用いた検出方法が提案されており、畳み込みニューラルネットワーク (CNN) をスライディングする方法 [2]、物体検出技術 YOLO(You Only Look Once) [3] を用いる方法 [4] がある。文献 [2] では、CNN を用いる方法は他の画像処理と比べて検出精度が高いことが報告されている。本研究では気泡検出に物体検出アルゴリズムである YOLO を使用する。このアルゴリズムは R-CNN [5] のような検索窓をスライドさせることなく画像を 1 回 CNN へ通すだけで物体を検出できるため、従来手法の中でも高速かつ高精度な認識を期待できる。

YOLO で気泡を検出する場合、教師データとして画像から気泡領域を切り出し、その領域の中心座標、大きさ等の位置情報が必要となる。この教師データを作る作業をアノテーションという。アノテーションは一般的に手動で行うため多大な労力と時間が必要になる。例えば、文献 [4] では、気泡のアノテーションを複数人で確認しながら行っている。

マイクロバブルは極小であるという点から、焦点が当たっている気泡と当たっていない気泡が混在する状態でカメラに写り、焦点が当たっているかどうかで気泡サイズを計測する際に大きく影響する。ここが一般的な気泡との違いである。この理由から、本研究では正確な気泡の大きさを求めるため、焦点が当たっている気泡のみを検出する。焦点が当たっている気泡についてはカメラからの距離が既知であるため、サイズを正確に求めることができる。焦点が当たっていない気泡については検出したとしても、正確な大きさを求めることができない。そのためアノテーションでも気泡の位置情報だけではなく焦点が当たっているという要素も必要となる。しかし、気泡の焦点が当たっているかどうかの基準は人によって大きく異なる。そのため、一定の基準でアノテーションを行うには、アノテーションを 1 人で行うかあるいは厳密に定めた基準を少数で共有して行う必要がある。しかし、実用的なシステムの開発では、学習に使用する画像枚数は 1000 枚を超えることもあるので、アノテーションに多大な労力が必要となる。そこで本研究では、YOLO を使って焦点のあった気泡を検出するためのアノテーション法を提案する。具体的には、画像処理を用いた焦点があっ

た円状の気泡の自動検出方法と手動による不定形や重なった気泡のアノテーション法を提案し、アノテーションの労力削減を目指す。

### 3 システム概要

#### 3.1 YOLO

本研究では、深層学習を用いた物体検出アルゴリズムの一つである YOLO(You Only Look Once) [3] を使用する。YOLO の構造を Fig. 1 に示す。

#### 3.2 全体の流れ

YOLO を使って物体検出システムを構築するには、前述のアノテーションを行う必要がある。本研究では、アノテーションの労力を削減するために、画像処理を使って自動で気泡を検出し、手動でのアノテーションの労力を削減することを試みる。Fig. 2 にシステム全体の流れを示す。まず、教師データの画像に対して画像処理を使った気泡検出アルゴリズムを適用する。具体的な手法は後述する。次に、検出対象の気泡を正しく検出できているか目視で確認する。この際、未検出の気泡を追加し、誤検出の気泡は削除する。そして、画像と気泡の位置情報で構成される教師データが完成する。教師データを使って学習し、学習に使っていない未知のデータ(テストデータ)に対して予測を行う。以上がシステム全体の流れである。




Fig. 1: The architecture of YOLO [3]

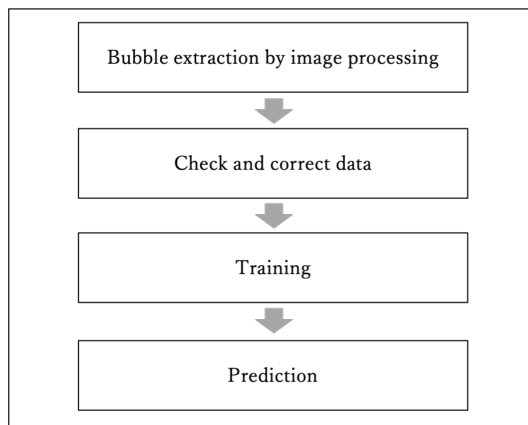


Fig. 2: System flow

### 4 提案方法

#### 4.1 基本的な考え方

水槽内にマイクロバブルを発生させる。Fig. 3 に撮影環境を示す。マイクロバブル発生装置先端から前方約 40 ミリメートルの位置にて、透明な水槽の外側からハイスピードカメラを用いて、透過光による近接撮影を行なう。Fig. 4(a) に撮影した画像の一例を示す。気泡の中心付近は明るく、周辺は暗く写っていることがわかる。気泡の中心は光の入射角が 0 と等しく光が入り、屈折せず光はそのまま進む。このため白く写る。気泡の中心から離れると入射角が大きくなるので、光は球面上で反射され、気泡の内部に入らなくなる。このため暗く写る。本稿では、この気泡内部の白い領域のことを内部領域とおく。また、気泡はほぼ円形になる。これらの特徴をもとにして画像からマイクロバブルの中心座標と半径を求める。

#### 4.2 画像処理による教師データの作成

- (1) 入力画像を 2 値化して、気泡の内部領域と輪郭をそれぞれ抽出する。入力画像の画素分布は背景画素と気泡の画素で二極化しているので、大津の二値化アルゴリズム [6] で二値化する。その後、二値画像から内部領域と輪郭を別々に取り出す。Fig. 4(b), Fig. 4(c) にそれぞれ Fig. 4(a) に対応する二値画像、内部領域と輪郭を示す。
- (2) 内部領域に気泡の中心点があると仮定し気泡を検出する。具体的には、Fig. 5(a) のように、内部領域に仮の中心点を定め、その点から輪郭までの距離を計算する。この計算は、輪郭画素全てに対して行う。その後、距離を要素番号とする 1 次元配列に計算結果を累積加算（投票）していく。Fig. 5(b) に内部領域の仮の中心点から求めた 1 次元配列の例を示す。横軸が半径、縦軸が累積値である。真円では中心点から円周上の画素までの距離が等しくなるため、1 次元配列では半径に対応する




Fig. 3: Shooting environment for microbubble

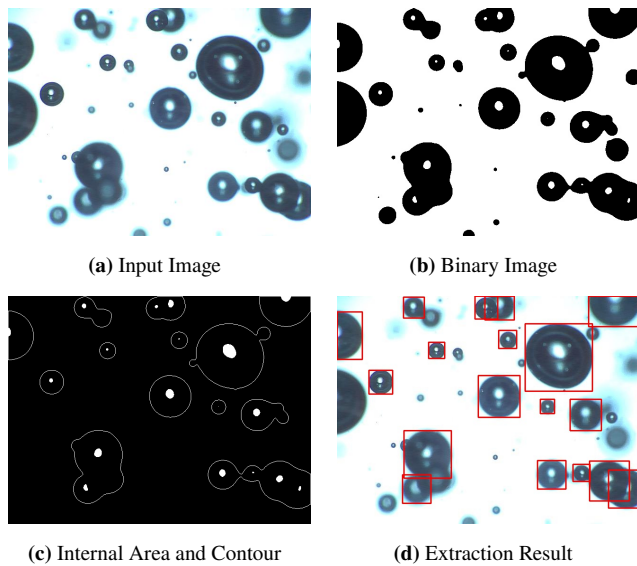


Fig. 4: Flow of creating training data using image processing




Fig. 5: How to determine the center point of micro bubble.

- Calculate the distance from the temporary center point to the contour.
- An example of a one-dimensional array.
- The figure which drew the red circle based on the information acquired in 4.2 (2).

要素で累積値がピークとなる。そこで仮の中心点毎の1次元配列から最も累積値が高くなるものを選び、その時の座標を中心点、要素番号を半径とする。Fig. 5(c)は上記工程を経て求められた円を画像上に描画したものである。

- 上記(2)を全ての内部領域について行う。このようにして画像内の全ての気泡の検出を行う。Fig. 4(d)にFig. 4(a)に対応する気泡の検出結果を示す。
- 検出した気泡に対して焦点があった気泡のみを検出する。具体的には、画像から検出した気泡を個々の画像として切り取る。次に切り取った気泡画像に対し Sobel フィルタを適用する。焦点があった気泡ではエッジが立っているため Sobel フィルタは大きな値を出力し、焦点がっていない気泡では小さな値を出力する。そこで気泡の輪郭画素に対応する Sobel フィルタの出力の平均値を求め、閾値を設定し、閾値より大きい平均値を持つ気泡のみを検出する。

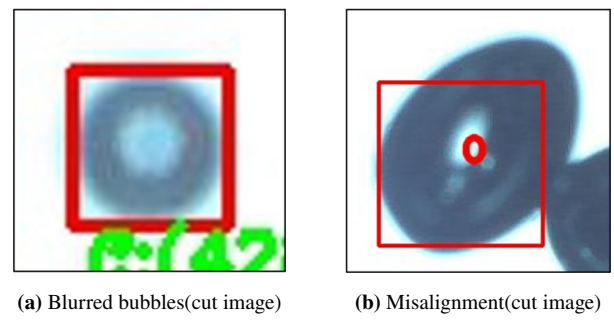


Fig. 6: Examples of false positive bubbles in image processing




Fig. 7: Examples of undetected bubbles in image processing

#### 4.3 手作業による教師データの作成

画像処理では、ぼやけた気泡をいくつか誤検出する。また、気泡の外接を正確に検出できないケースがある。Fig. 6(a)にぼやけた気泡の誤検出、Fig. 6(b)気泡の外接を正確に検出できていない例を示す。そして、歪んだ形状の気泡や複雑に重なった気泡を検出することができない。Fig. 7(a)に歪んだ形状の気泡、Fig. 7(b)に複雑に重なった気泡を示す。これらの気泡を手動で削除・追加し、教師データを補正する。

### 5 実験

#### 5.1 教師データ

教師データは、気泡 633 個を含んでいる学習用画像 100 枚に対するアノテーションにより作成する。アノテーションの方法は、以下のとおりとする。

- 方法 1 : 手動
- 方法 2 : 画像処理
- 方法 3 : 画像処理+修正 (手動)
- 提案法 1 : 画像処理+追加 (手動)
- 提案法 2 : 画像処理+修正 (手動) + 追加 (手動)

Table. 1 に方法ごとの教師データ数を示す。方法 1 は画像に含まれる全ての気泡を手動でアノテーションしたものである。方法 2 は画像処理で検出した結果を教師データとする方法である。今回の実験では、画像処理で 349 個が出

**Table. 1:** Structure of training data

	Image processing (Automatic)	Deletion (Manual)	Addition (Manual)	The number of training data
Method 1	0	0	633	633
Method 2	349	0	0	349
Method 3	349	60	0	289
Proposed method 1A	349	0	344	693
Proposed method 1B	349	0	172	521
Proposed method 2A	349	60	344	633
Proposed method 2B	349	60	172	461


力されたため、これらを教師データとする。方法3は画像処理の結果から誤検出した気泡を削除する方法である。今回の実験では60個が誤検出されていたため、これらを削除したものを教師データとする。提案法1は画像処理の結果に未検出の気泡を追加する方法である。今回の実験では344個の気泡が未検出であったため、これらを追加したものを教師データとする。なお比較のため、未検出の半分(172個)だけを追加した方法も用意する。これらをそれぞれAとBで区別する。提案法2は提案法1に対し、画像処理の結果の修正を行う方法である。提案法1と同様に追加する数をAとBで区別する。

## 5.2 YOLO による検出結果

教師データ毎にYOLOを学習させる。それぞれ学習したYOLOを用いて、学習時に使用していない評価用画像111枚(気泡合計数505個)に対して、検出精度を調べる。なお、正解ラベルは目視で作成した。

個々の気泡が検出できたかの指標として、IoU(Intersection over Union)を使用した。Fig. 8にIoUの概略図を示す。赤枠がシステムの検出結果で緑枠が正解データとすると、分母にその和集合、分子にその共通部分を取ることで算出される。IoUは0~1の値となる。実験では閾値を0.5とし、0.5以上であれば正しく検出できたと判定した。

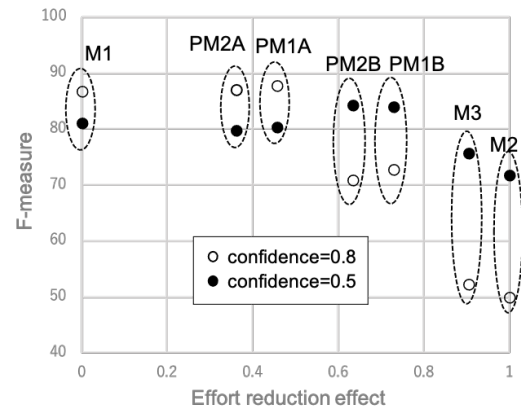
YOLOによる505個の気泡の検出評価の指標として、適合率、再現率、F値を使用した。以下に示す式で求められる。

**Fig. 8:** Intersection over Union**Table. 2:** Detection results for each annotation method when the confidence threshold is set to 0.5 and 0.8

Method	confidence=0.5			confidence=0.8		
	P	R	F	P	R	F
Method 1	71.4	93.7	81.1	89.8	83.8	86.7
Method 2	83.5	63.0	71.8	95.0	33.9	49.9
Method 3	90.4	65.2	75.7	98.9	35.4	52.2
Proposed method 1A	68.8	96.2	80.3	88.5	86.9	87.7
Proposed method 1B	83.4	84.6	84.0	95.5	58.8	72.8
Proposed method 2A	68.8	94.8	79.8	87.7	86.5	87.0
Proposed method 2B	86.9	81.6	84.2	97.6	55.6	70.9

**Table. 3:** Manual Extraction Result

Method	Precision	Recall	F-measure
Student 1	82.07	83.37	82.71
Student 2	100.00	45.74	62.77
Student 3	96.69	63.56	76.70

**Fig. 9:** Relationship between F-measure and effort reduction effect of annotation for each method

- 適合率  $P$  = 正解判定数 / 全判定数
- 再現率  $R$  = 正解判定数 / 正解データ数
- $F$  値 = 適合率と再現率の調和平均

実験は、信頼度の閾値を0.2~0.9まで0.1刻みで設定し行った。Table. 2に信頼度の閾値を0.5と0.8とした時の教師データのアノテーション方法ごとの検出結果を示す。信頼度とは、学習済YOLOが予測時に出力する0~1のスコアである。1に近いほど気泡であると判断している。

## 5.3 手動による検出結果

人によって結果がどの程度ばらつくかを調べるために、学生3名に協力してもらい、目視による検出実験を行った。テストデータに対して、ピン트가合っている気泡だけを検出するように指示した。Table. 3に検出結果を示す。



## 6 考察

### 6.1 アノテーションの労力軽減と F 値の関係

アノテーションの労力軽減の効果を以下の式で定義する。

$$\text{労力軽減効果} = 1 - (\text{手動入力的气泡数} / \text{真的气泡数})$$

Table. 1 より労力軽減効果は全ての気泡 (633 個) を手動で入力する方法 1 が 0, 画像処理の結果のみを使い手動入力しない方法 2 が 1 となる。その他は, 方法 3, 提案法 1A, 提案法 1B, 提案法 2A, 提案法 2B はそれぞれ 0.9, 0.46, 0.73, 0.36, 0.63 となる。

Fig. 9 に方法ごとのアノテーションの労力軽減効果と F 値の関係を示す。Fig. 9 より以下のことがわかる。

- ・提案法 1A(PM1A), 提案法 2A(PM2A) は, アノテーションを全て手動で行う方法 1(M1) と比較して, 検出精度を低下させることなく, アノテーションの労力を約 40% 軽減できている。
- ・提案法 1B(PM1B), 提案法 2B(PM2B) の信頼度 0.5 のときの F 値 (84%) は, 提案法 1A, 提案法 2A の最高の結果 (信頼度 0.8 のときの F 値) と比べて, 3% 程度低下するが, 労力は約 70% 軽減できている。これより検出精度が 3% 程度低下することを許容できれば, アノテーションの労力を大きく軽減できる。
- ・提案法 1A と提案法 2A, および提案法 1B と提案法 2B はそれぞれほぼ同じ F 値となっている。これより今回の実験では画像処理の結果に対する修正の効果は見られない。ただし, 方法 2(M2) と方法 3(M3) では画像処理の結果に対する修正を行う方法 3 の F 値が向上している。これより教師データ数が少ない場合は品質が高いほうがよく, 多い場合は多少品質が悪くても影響が少ないことが考えられる。
- ・信頼度の閾値が 0.5 の時と 0.8 の時と比べると, 再現率は向上しているが, 適合率は低下しており調和平均である F 値も低下している。これは, 気泡であると判断する基準を下げたことにより, 真陽性判定が増えたが, 誤検出も増えているということになる。

### 6.2 人による入力との比較

Table. 3 より, 人が同じような基準で気泡を検出しても, 結果には大きなばらつきが生じることが分かる。これは, ピントがあっているかどうかや, 画面端で切れた気泡が検出対象かどうかの線引きが人によって異なるということであり, 問題自体が難解なものと言える。これらを踏まえて考えると, YOLO による気泡検出 (方法 1, 提案法 1A, 提案法 2A) の結果は概ね良好であると言える。

### 6.3 検出例

Fig. 10 に, 信頼度の閾値が 0.8 のときの YOLO による検出結果の一例を示す。Fig. 10(a) は正解画像, Fig. 10(b)

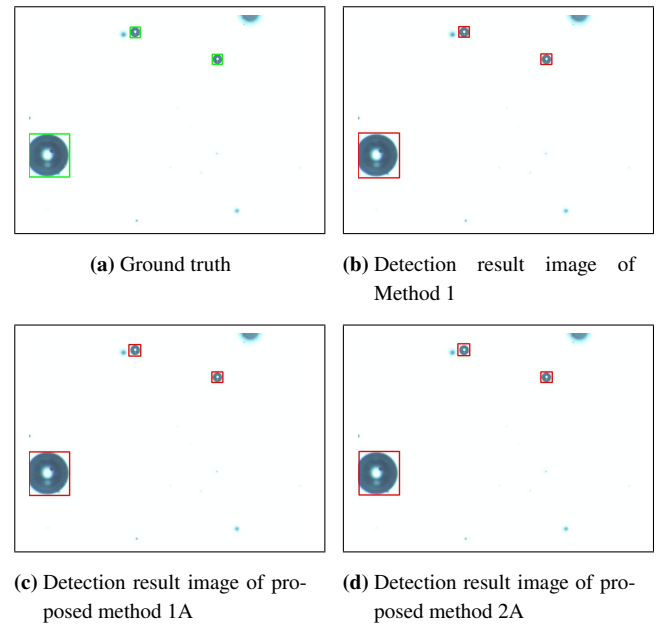


Fig. 10: Example of detection results by YOLO when the confidence threshold is 0.8.

～Fig. 10(d) は, それぞれ方法 1, 提案法 1A, 提案法 2A で学習した YOLO での検出例である。これらの結果より, それぞれの教師データで学習した YOLO において気泡が良好に検出できていることがわかる。

Fig. 11 に信頼度の閾値を 0.5 としたときの検出失敗例を示す。各 YOLO において, 左の画面端で切れた気泡と右下の気泡の外形は半分以上写っているばやけた気泡を誤検出していることが分かる。また, 相対的に小さい気泡の未検

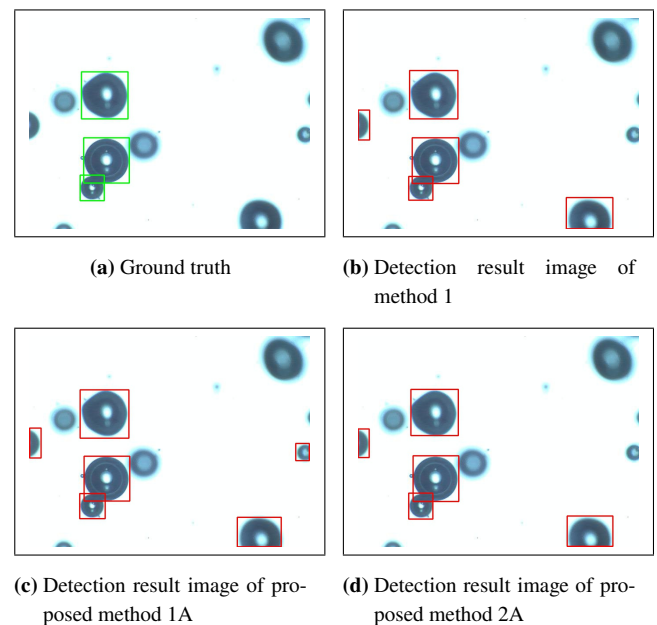
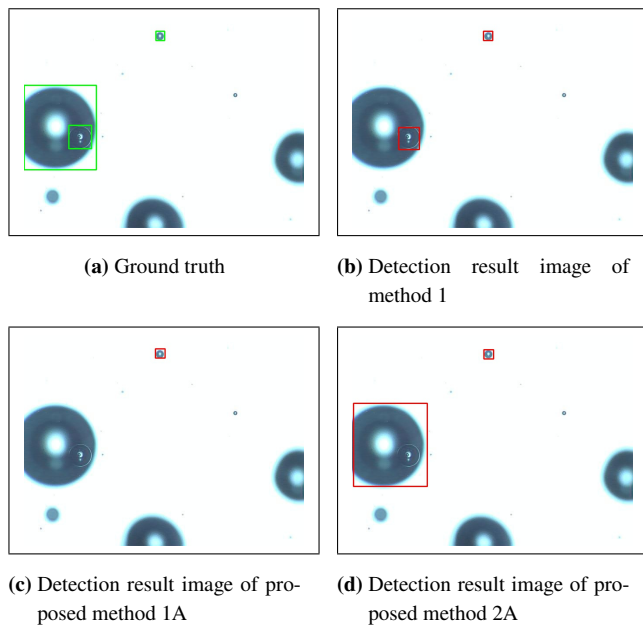


Fig. 11: Example of detection failure when the confidence threshold is 0.5



**Fig. 12:** Example of detection failure when the confidence threshold is 0.8

出も見られた。

Fig. 12 に信頼度の閾値を 0.8 としたときの検出失敗例を示す。方法 1 と提案法 2A で学習した YOLO では、画像左端に写っている気泡に関して、信頼度の閾値をあげたことにより若干ばやけた気泡が検出できなかった。また、提案法 1 A と提案法 2A で学習した YOLO では完全に気泡の外形が重なっていることで検出できなかった。この気泡は、そもそも教師データが少ないことが原因でもあったと考えられる。ただし、信頼度の閾値を下げればこれらの気泡は検出できる。

## 7 結言

本研究では、画像処理を使ってマイクロバブルを定量評価するシステムの開発を目指した。また、アノテーションの労力を削減することも目標とした。提案手法では、まず、教師データに使う画像データセットに対して画像処理を使った方法で気泡を自動検出した。その後、手動で未検出気泡の追加と誤検出気泡の削除を行った。このような流れで教師データを作成した。実験では、複数の教師データから複数の YOLO モデルを作成してそれらのモデルの検出精度を比較した。画像処理と手動で全ての気泡をアノテーションする提案手法 1A, 2A はアノテーションを完全に手動で行ったモデルに比べ F 値は同等で労力を約 40% 軽減できた。また手動での入力を半分に減らした提案方法 1B, 提案方法 2B では F 値が 3% 程度低下したが労力を約 70% 軽減できた。検出精度が約 3% 下がることを許容できれば、システムユーザは手動によるアノテーションの労力を大き

く減らすことができ、YOLO を使った気泡検出を容易に実現できるのではないかと考える。今後の課題として、画像処理での検出精度をさらに向上させ、手動での労力をさらに軽減させることが挙げられる。

## 謝辞

本研究を進めるにあたってご指導いただいた、電子制御工学科志久修先生、手島裕詞先生に厚くお礼申し上げます。気泡計測についてご教授いただき、気泡画像をご提供いただいた機械工学科松山史憲先生に深く感謝いたします。また気泡のアノテーションをお手伝いいただいた機械工学科松山研究室の学生の方々に感謝いたします。

## 参考文献

- [1] Ashutosh Agarwal, Wun Jern Ng, Yu Liu "Principle and applications of microbubble and nanobubble technology for water treatment", August 2011.
- [2] Jarmo Ilonen, Roman Juránek, Tuomas Eerola, Lasse Lensu, Markéta Dubská, Pavel Zemčík, Heikki Kälviäinen, "Comparison of bubble detectors and size distribution estimators", Pattern Recognition Letters 101 (2018) 60-66.
- [3] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi, "You Only Look Once: Unified, Real-Time Object Detection", In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 779-788, 2016
- [4] 鳥崎修平, 三輪修一郎, "気泡検出アルゴリズムを用いた気液二相流画像解析," 混相流, 34, 1, pp.125-133, 2020.
- [5] Girshick, R., J. Donahue, T. Darrell, and J. Malik. "Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation." CVPR '14 Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. Pages 580-587. 2014
- [6] N. Otsu, "A threshold selection method from gray-level histograms," IEEE Trans. Syst. Man Cybern., vol.9, no.1, pp.62-66, 1979.